

BIẾT MÌNH KHÔNG BIẾT

Trợ lý Discord tối ưu cho học viên AI20K – Chuyển TA câu hỏi hồ sơ cá nhân thay vì đoán mò

👤 NHÓM GICUNGDCZ · LỚP 3A · PHÒNG E403

Track B1: Tối ưu trợ lý học viên Discord hiện có. Giải quyết bài toán then chốt: nhận diện đúng câu hỏi thẩm quyền cá nhân và biết-mình-không-biết.

THÀNH VIÊN	MÃ HV	VAI TRÒ ĐẢM NHIỆM
Nguyễn Đức Thắng	2A202602605	Leader · Data Mining & Điều phối
Trần Anh Quân	2A202602598	BA · Phỏng vấn & Phân tích Spec
Nguyễn Hải Long	2A202602471	Dev · Quyết định AI Gemini & Prototype
Ngô Tiến Dũng	2A202602374	Tester · Thiết kế Golden Set & Eval

B1

TRACK THI

100%

PYTHON THUẦN

96%

ĐỘ CHÍNH XÁC

🕒 CORE JTBD & TUYÊN BỐ VẤN ĐỀ

JOB TO BE DONE (HỌC VIÊN BUILD PHASE)

"Khi nghĩ mình chưa được ghi nhận điểm danh, XP hay bài nộp, tôi muốn biết chắc trạng thái của mình và ai sửa được, để khắc phục kịp trước khi mất điểm."

! Chỗ đứt gãy nguy hiểm trên Discord hiện tại

Học viên tag bot hỏi về hồ sơ cá nhân. Bot **không có quyền** xem hay sửa hồ sơ nhưng lại trả lời lạc đề, phỏng đoán sai hoặc bắt chọn menu. Câu hỏi **không bao giờ đến được TA/Mod**, khiến học viên hoang mang và đối mặt nguy cơ mất điểm thật.

GIẢI PHÁP ĐỘT PHÁ CỦA GICUNGDCZ

AI nhận diện câu hỏi thẩm quyền cá nhân ngay trong 1 lượt → Tóm tắt ngữ cảnh chuẩn xác → Chuyển thẳng hàng đợi TA, bot **tuyệt đối không bịa đặt** trạng thái.

DỮ LIỆU THỰC TẾ: BOT CŨ SAI ĐẾN 92%

Khai phá 1.092 tin nhắn Discord K4 (12–14/09) – Bảng chứng định lượng không thể chối cãi

PHÂN TÍCH 13 TIN NHẮN HỒ SƠ CÁ NHÂN (13 NGƯỜI KHÁC NHAU)

92%

BOT XỬ LÝ SAI

12 / 13 ca thất bại

31%

HỎI LẠI TRONG 30'

4 / 13 người bế tắc

1/13

TAG ĐÚNG MOD

Chỉ có 1 ca M98666

CÁCH BOT CŨ XỬ LÝ	SỐ CA	HẬU QUẢ ĐỐI VỚI HỌC VIÊN
Soạn sẵn lặc đề	6 ca	Học viên tưởng hệ thống bình thường, bỏ lỡ hạn sửa điểm danh.
Phỏng đoán / Giải thích dài	4 ca	Bot tự suy đoán lịch sử (dài tới 1.192 ký tự!), tạo ảo tưởng sai.
Menu máy móc 3 lựa chọn	2 ca	Bắt người dùng chọn lại dù câu hỏi ban đầu đã rất rõ.
Chuyển Mod hỗ trợ	1 ca	Hành vi đúng duy nhất (chỉ chiếm 7.7%).

Đánh đổi có tính toán:

Dù số ca hồ sơ cá nhân (13) ít hơn Standup (60), nhóm vẫn quyết định chọn bài toán này vì **hậu quả mất điểm là không thể phục hồi** và **tỉ lệ bot sai cao kỷ lục (92%)**.

Evidence Mining - Phân bố ngày: 12/09 (5 tin) · 13/09 (3 tin) · 14/09 (5 tin)

TRÍCH DẪN NGUYÊN VĂN BẢNG CHỨNG THẬT

Học viên đặt sai tên Zoom

msg_id: M45740

"mình đặt sai cú pháp khi tham gia zoom workshop nên không được ghi nhận, mình nên xử lí như nào"

Bot cũ: "Tham gia workshop đăng nhập Zoom với đúng email đã đăng ký..." (Nhắc lại quy tắc người ta vừa lỡ vi phạm, không chuyển TA)

Học viên kiểm tra nộp bài

msg_id: M84993

"check xem t đã nộp bài codelab chưa"

Bot cũ: "Bài Lab trên lớp sẽ được chấm sau khi hết deadline thường là 23:59 cùng ngày nhé" (Đoán deadline, không biết trạng thái nộp)

Học viên tra lịch sử điểm danh

msg_id: M73901

"mình muốn kiểm tra lịch sử điểm danh thì xem ở đâu"

Bot cũ: "Các bạn có thể theo dõi hoặc tìm kiếm điểm XP của mình bằng Discord ID..." (Hỏi điểm danh trả lời XP)

Dữ liệu kiểm chứng độc lập từ pack tin nhắn công khai K4.

Chuẩn xác minh: spec.md §1 & validation/survey-pain.md

LÁT CẮT 1 CÂU & THIẾT KẾ CONDITIONAL

Áp dụng HAX Toolkit (Microsoft) và PAIR Guidebook (Google) để giảm thiểu chi phí sai lầm

LÁT CẮT SẢN PHẨM & MA TRẬN COST-OF-ERROR

LÁT CẮT MỘT CÂU (CORE SLICE)

"Một học viên hỏi bot về hồ sơ của chính mình → AI phân loại → Chuyển ngay cho TA kèm tóm tắt trong 1 lượt, bot tuyệt đối không tự khẳng định trạng thái."

KỊCH BẢN SAI	HẬU QUẢ THỰC TẾ	MỨC ĐỘ CHI PHÍ
Bot tự đoán câu cá nhân	Học viên tin sai, mất điểm danh/XP/lab	CỰC CAO (Không đảo ngược)
Chuyển nhầm cho TA	TA tốn 2 giây bấm "Không phải hồ sơ"	RẤT THẤP (Sửa tức thì)
Hỏi lại khi câu hỏi rõ	Học viên bấm thêm 1 nút xác nhận	THẤP

💡 **Conditional Automation:** Ngưỡng quyết định cố tình lệch hẳn về phía chuyển TA (Confidence $\geq 0.75 \rightarrow$ Handoff ngay). Chuyển nhầm chỉ tốn vài giây, nhưng đoán mò sẽ đánh mất tương lai của học viên.

HIỆN THỰC HOÁ NGUYÊN TẮC HAX & PAIR

G1 HAX G1 · Nói rõ giới hạn bot
Mọi câu trả lời mở đầu: "Mình không xem được hồ sơ cá nhân". Tránh việc học viên ngộ nhận bot là admin.

G10 HAX G10 · Thu hẹp khi nghi ngờ
Khi mơ hồ (độ tin 0.45 - 0.75), chỉ hỏi lại đúng 1 câu với 2 nút, loại bỏ triệt để menu đa tầng.

G11 HAX G11 · Giải thích lý do
Khung thu gọn "Vì sao chuyển TA?" bóc tách rõ tín hiệu (đại từ, từ khóa hồ sơ, độ tự tin AI).

G9 HAX G9 & PAIR Graceful Failure
Nút "✏️ Sửa tóm tắt", "🗑️ Bot hiểu sai" (1 click). Thiếu nguồn chính thức → thẳng thắn từ chối bịa đặt.

✓ Đã hiện thực hoá đầy đủ trên prototype web mô phỏng.

KIẾN TRÚC AI THẬT & PHỦ KỊCH BẢN RỦI RO

1 lời gọi Gemini trích xuất JSON cấu trúc + Rule Engine cố định + Ghi vết (logging) minh bạch

🖥️ PIPELINE QUYẾT ĐỊNH (WORKING PROTOTYPE)

- Tin nhắn học viên (Discord Tag)**
Được bao bọc trong tag <tin_nhan>, coi là DỮ LIỆU thuần túy, phòng thủ injection.
- LLM Call Thật (Gemini 2.5 / 3.5 Flash)**
Trích xuất JSON cấu trúc: intent, confidence, record_type, urgent, injection, summary.
- Rule Engine Định Tuyến Cố Định (route)**
Ngưỡng 0.75 (Handoff) / 0.45 (Clarify). LLM không tự sinh câu văn bừa bãi mà theo template an toàn.
- Hàng Đợi TA (Handoff Queue) & Ghi Vết**
Tạo thẻ cho TA kèm tóm tắt. Ghi toàn bộ prompt + phản hồi thô vào file llm_calls.jsonl.

POST /api/decide → {"route": "handoff", "latency_ms": 3800}

★ 6 ĐƯỜNG TRẢI NGHIỆM ĐÃ PHỦ TRÊN DEMO

1. Happy Path

Hỏi điểm danh rõ (≥ 0.75) → Tóm tắt ngắn chuyển thẳng thẻ TA.

2. Low-Confidence

Hỏi mơ hồ (0.45 - 0.75) → Hỏi lại đúng 1 câu, 2 nút bấm.

3. No Grounding

Không có trong FAQ → Không đoán mò, dẫn link #thông-báo.

4. User Correction

Học viên/TA bấm nút sửa sai → Hủy thẻ, ghi log cải tiến.

5. Prompt Injection

Tin cố ý ra lệnh cho bot → Bật cờ injection, từ chối lệnh.

6. Domain Đặc Thù

Hỏi hộ người khác (chặn lộ tin) · Sát deadline (gắn cờ GẤP).

Tất cả 6 kịch bản đều bấm thử trực tiếp được tại trang /demo.

KẾT QUẢ ĐO LƯỜNG: 24/25 CA ĐẠT (96%)

Chạy tự động bằng run_eval.py trên 25 ca thử thách – Phân tích trung thực ca lỗi H2-1

✓ KẾT QUẢ THEO TỪNG NHÓM KIỂM THỬ TRONG GOLDEN SET

96%

TỔNG ĐẠT
24 / 25 ca

18/18

TIN THẬT K4
100% ca có
msg_id

100%

CHỐNG
INJECTION
3 / 3 ca an toàn

3.8s

ĐỘ TRỄ TRUNG
VỊ
Gemini Flash API

NHÓM TEST CASE	SỐ CA	ĐẠT	TỈ LỆ	ĐẶC ĐIỂM KIỂM CHỨNG
Phổ biến hằng ngày	10	10	100%	Hỏi điểm danh, XP, nộp bài (M45740, M84993...)
① Nguồn sự thật	3	3	100%	Hỏi deadline chưa công bố → No grounding
② Mơ hồ / thiếu thông tin	3	2	67%	Lỗi ca H2-1 ("check điểm danh như nào")
③ Ngoài phạm vi / Thăm quyền	3	3	100%	Chặn chỉ dẫn lạ, Prompt Injection
④ Đặc thù nghiệp vụ	3	3	100%	Sát hạn nộp (urgent) & Hỏi hộ bạn khác
Edge Cases (Không dấu, tin kép)	3	3	100%	Đo bù E1 (tiếng Việt không dấu) & E2 đạt xuất sắc

Đánh giá tự động khách quan · Không can thiệp tay vào kết quả
Tất cả log gọi LLM được lưu độc lập tại eval/runs/ để chấm chéo.

✖ PHÂN TÍCH TRUNG THỰC CA LỖI DUY NHẤT (H2-1)

Ca H2-1 (msg_id: M55443)

"check điểm danh như nào"

Nguyên nhân: Lỗi ở luật định tuyến (Rule Engine), không phải ở Model Gemini!

- Model nhận diện đúng câu hỏi mơ hồ và hạ độ tin cậy xuống 0.60.
- Tuy nhiên, vì gán nhãn GENERAL nên luật route() bỏ qua nhánh hỏi lại (Clarify) và chuyển thẳng vào no_grounding.

Bài học & Hướng khắc phục (Lượt 2)

Cập nhật hàm route(): Nếu câu GENERAL có độ tin cậy < 0.75 và nhắc tới hồ sơ thì kích hoạt nhánh hỏi lại (Clarify). Điều này chứng minh hệ thống an toàn vì không bịa đặt.

Căn cứ: spec.md §7 & eval/run_results.md
Trích xuất từ: eval/run_results.md

NGƯỜI NGOÀI DỪNG THỬ & KẾ HOẠCH TƯƠNG LAI

Quan sát 5 học viên K4 thao tác thực tế theo chuẩn Mom Test — Đưa phản hồi vào Changelog



NHẬT KÝ THỬ NGHIỆM 5 NGƯỜI DỪNG (R6 ĐẠT 8/8 ĐIỂM)

Gồm 2 willing users đã đăng ký từ CP1: Lương Khánh Toàn (U1) & Dương Minh Hiếu (U2) + 3 học viên K4 ngoài nhóm (U3, U4, U5).

U1 (Lương Khánh Toàn · Khai từ CP1)

Task: Hỏi điểm danh Zoom

"Bấm gửi xong thấy có tóm tắt gửi cho TA là yên tâm hẳn, không sợ bot trả lời linh tinh như mấy hôm trước."

U2 (Dương Minh Hiếu · Khai từ CP1)

Task: Hỏi XP daily

"Nút 'Bot hiểu sai' khá tiện, đỡ phải gõ lại từ đầu nếu mình chỉ muốn hỏi quy định chung."

U3 (Học viên K4 non-IT)

Task: Check deadline bài tập

"Bot nói thẳng không có thông tin và dẫn link thông báo đỡ làm mình mất thời gian đoán mò."

✓ Đã cập nhật ít nhất 1 thay đổi trực tiếp vào spec.md §9 Changelog.



BÀI HỌC THIẾT KẾ & KẾ HOẠCH TRIỂN KHAI

1. Thay đổi thiết kế từ Validation

Thêm hiển thị badge "Ước tính TA phản hồi < 2h" trong khung tóm tắt, giúp học viên an tâm không spam hỏi lại nhiều lần.

2. Tích hợp Discord Bot API thật

Đóng gói webhook chạy nền, tự động tạo Forum Thread riêng cho từng ca chuyển giao TA để bảo mật thông tin cá nhân.

3. Mở rộng TA Dashboard & Tự động hoá FAQ

Đồng bộ các câu hỏi chưa có trong nguồn chính thức vào Google Sheets để ban tổ chức cập nhật thông báo kịp thời.

SẴN SÀNG CHO BUỔI THUYẾT TRÌNH CHECKPOINT 6! 🚀